I302 - Aprendizaje Automático y Aprendizaje Profundo

Trabajo Práctico 2: Clasificación y Ensemble Learning

Ana Paula Tissera

15 de abril de 2025

Ingeniería en Inteligencia Artificial

1. Diagnóstico de Cáncer de Mama

Resumen

En esta sección se abordó el diagnóstico de cáncer de mama mediante un modelo de regresión logística binaria con regularización L2, optimizado por descenso por gradiente. Para ello, se empleó un conjunto de datos balanceado así como otro desbalanceado de biopsias histopatológicas al cual se aplicó un preprocesamiento que incluyó detección y corrección de outliers, imputación de valores faltantes con KNN, codificación de variables categóricas y estandarización de características. La selección de hiperparámetros (coeficiente de regularización λ) se realizó mediante barrido logarítmico y validación en el conjunto de desarrollo, optimizando el F1 Score. En el conjunto balanceado de test, el modelo alcanzó un accuracy de 0.9459, F1 score de 0.9398, AUC-ROC de 0.9571 y AUC-PR de 0.8688; y en escenarios desbalanceados demostró un F1-score de 0.9189 AUC-PR de hasta 0.784 mediante oversampling, posicionándose apenas por encima de los otros métodos de re-muestreo.

1.1. Introducción

El problema de Diagnóstico de Cáncer de Mama consiste en determinar, a partir de datos obtenidos de biopsias histopatológicas, si un tumor es benigno o maligno, es decir, predecir la variable `Diagnosis`. Las entradas del algoritmo son mediciones morfológicas y moleculares que incluyen variables como el tamaño y la forma de las células, la densidad nuclear, la tasa de mitosis, y la presencia de ciertas mutaciones. A partir de estos datos se emplean técnicas de clasificación; en este trabajo se utilizan modelos de regresión logística regularizados mediante L2, con el objetivo de generar una etiqueta diagnóstica que facilite la toma de decisiones clínicas y la planificación de tratamientos adecuados.

1.2. Métodos

1.2.1. Regresión Logística

La regresión logística es un modelo de clasificación discriminativa que estima la probabilidad condicional $p(y \mid x; \theta)$, donde $x \in R^D$ representa la entrada y $\theta = (w, b)$ los parámetros del modelo, con $w \in R^D$ y $b \in R$ [1]. En el caso binario, la probabilidad de la clase positiva se modela mediante la función sigmoide:

$$p(y = 1 \mid x; \theta) = \sigma(w^T x + b) = \frac{1}{1 + \exp(-w^T x - b)}, \tag{1}$$

y la de la clase negativa como $p(y = 0 \mid x; \theta) = 1 - \sigma(w^T x + b)$.

El entrenamiento consiste en minimizar el negativo del log-likelihood (NLL) regularizado con un término L2 para mitigar el sobreajuste. La función de pérdida binaria queda entonces definida como:

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{n=1}^{N} \left[y_n \log \sigma(w^T x_n + b) + (1 - y_n) \log(1 - \sigma(w^T x_n + b)) \right] + \frac{\lambda}{2} \|w\|^2, \tag{2}$$

donde N es el número de ejemplos y λ el coeficiente de regularización.

La optimización de los parámetros se realiza mediante descenso por gradiente, aprovechando la convexidad de la pérdida para asegurar la convergencia al óptimo global. La regularización L2 también permite obtener una estimación MAP (Maximum A Posteriori), clave en contextos de alta dimensionalidad.

1.2.2. Conjunto de Datos y Preprocesamiento

Para el análisis se utilizó en primera instancia un conjunto de datos de diagnóstico de cáncer de mama balanceado, que se encontraba dividido en dos particiones principales: un conjunto de desarrollo (*dev*) y un conjunto de test. Durante la etapa de desarrollo, en el conjunto de *dev* se aplicó una partición aleatoria con una proporción de 80 % para entrenamiento y 20 % para validación, mientras que el conjunto de test es independiente y se empleó para evaluar el desempeño final de los modelos.

La fase de preprocesamiento se inició con un análisis de los valores faltantes y la exploración de las estadísticas descriptivas de cada feature, lo cual permitió definir rangos válidos o convenientes para las variables. Los gráficos correspondientes a este análisis se encuentran en el notebook entregado. A partir de estos rangos, se procedió a detectar y corregir outliers, reemplazando los valores que excedían los límites definidos por valores nulos. Sobre esta base, se imputaron los valores faltantes utilizando métodos básicos (como la media y la moda) complementados con técnicas basadas en vecinos cercanos (KNN) para mejorar la integridad de los datos. Para más información sobre cómo se implementó esta técnica consultar el apéndice en la Sección 2.4. Un ejemplo del efecto del preprocesamiento sobre la distribución de una variable puede verse en dicha Sección en la Figura 7.

Una vez corregidos los valores atípicos y completados los datos, se realizaron transformaciones en las variables de entrada: se aplicó el one-hot encoding sobre la columna correspondiente a los tipos celulares y se codificó de forma binaria la variable que indicaba la presencia o ausencia de mutaciones genéticas. Finalmente, se procedió a normalizar las características numéricas mediante estandarización, omitiendo las columnas binarias:

$$z = \frac{x - \mu}{\sigma}, \tag{3}$$

Donde x es el valor original, μ es la media de la variable y σ es el desvío estándar. Esta transformación se realizó de manera consistente en los conjuntos de entrenamiento, validación y test, utilizando los estadísticos calculados en el conjunto de entrenamiento para transformar los demás subconjuntos.

Para escenarios en los que el conjunto de datos presentaba un desbalance entre las clases, se implementaron diversas estrategias de remuestreo. Se consideraron estrategias de undersampling para reducir la cantidad de muestras de la clase mayoritaria, oversampling mediante duplicación de la clase minoritaria, la generación de ejemplos sintéticos mediante SMOTE y el cálculo de pesos cost-sensitive basados en las proporciones de clase, como se explicará más adelante. Cada uno de estos métodos fue aplicado y evaluado de manera independiente para determinar su impacto en el desempeño de los modelos.

1.2.3. Selección de Hiperparámetros y Métricas de Rendimiento

La elección del hiperparámetro λ (coeficiente de regularización L2) se realizó mediante un barrido en el rango logarítmico, mientras que para la tasa de aprendizaje y cantidad de

iteraciones se utilizaron valores estándares. Para cada valor de λ se entrenó el modelo durante 1000 iteraciones en el conjunto de entrenamiento, y se evaluó su desempeño en el conjunto de validación utilizando el F1 Score. Esta métrica se define como:

$$F_1 = 2 \cdot \frac{P \cdot R}{P+R} \tag{4}$$

donde la precisión P y el recall R se calculan como:

$$P = \frac{TP}{TP+FP}, \quad R = \frac{TP}{TP+FN} \tag{5}$$

con TP (true positives), FP (false positives) y FN (false negatives). El valor de λ que maximizó el F1 Score en el conjunto de validación fue seleccionado para el entrenamiento final del modelo.

Las métricas utilizadas para evaluar la performance del modelo entrenado fueron:

- **Matriz de Confusión**: permite visualizar la distribución de los casos en verdaderos positivos (TP), falsos positivos (FP), verdaderos negativos (TN) y falsos negativos (FN), proporcionando una representación directa del comportamiento del modelo.

	Predicho: Positivo	**Predicho: Negativo**
Real: Positivo	TP	FN
Real: Negativo	FP	TN

- **Accuracy**: mide la proporción de predicciones correctas sobre el total de muestras, definida como

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN} \tag{6}$$

- **Precision** y **Recall**, cuyos cálculos se muestran en la Ecuación (5); reflejan cuán precisas son las predicciones positivas, intentando evitar falsos positivos, y cuántos positivos reales fueron capturados, minimizando falsos negativos, respectivamente.
- **F1 Score**: como se indicó en la Ecuación (4); combina precisión y recall en una única métrica balanceada.
- **AUC-ROC**: es el área bajo la curva ROC, obtenida por integración trapezoidal sobre la relación entre TPR y FPR; mide la capacidad de distinguir entre clases a distintos umbrales.
- **AUC-PR**: área bajo la curva Precision-Recall, también calculada mediante integración trapezoidal; más informativa que ROC en escenarios desbalanceados.

1.3. Resultados

1.3.1. Entrenamiento y Evaluación en el Conjunto Balanceado

Se entrenó un modelo de Regresión Logística binaria con regularización L2, buscando el hiperparámetro λ óptimo mediante un barrido logarítmico en $\lambda \in [10^{-2}, 10^{2}]$. El mejor valor encontrado fue $\lambda = 0.01$, con el cual se obtuvo un F1 Score de 0.9 en el conjunto de validación.

Una vez seleccionado el hiperparámetro λ óptimo, se reentrenó el modelo utilizando todo el conjunto de desarrollo. Finalmente, se evaluó su desempeño en el conjunto de test. Las Figuras 1a, 1b y 1c muestran, respectivamente, la matriz de confusión, la curva ROC y la curva Precision-Recall obtenidas sobre dicho conjunto.

Como se observa en la matriz de confusión de la Figura 1a, el modelo logró una alta tasa de aciertos con pocos errores de clasificación. La curva ROC (Figura 1b) exhibe una muy buena

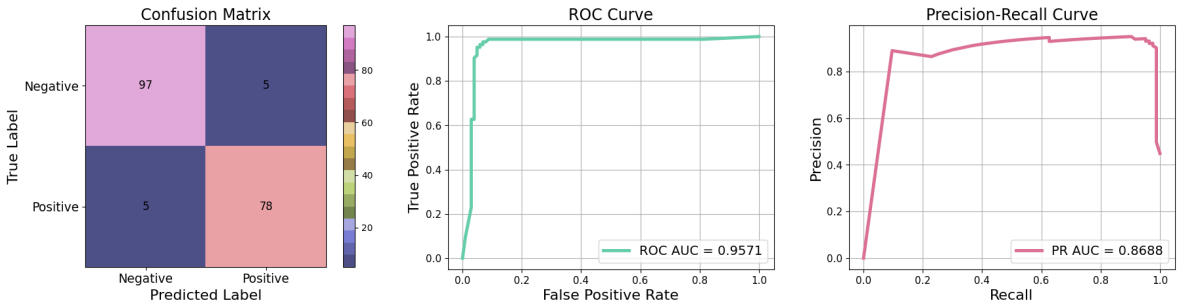

(a) Matriz de confusión (b) Curva ROC (c) Curva PR

Figura 1: Comparación de la matriz de confusión, la curva ROC y la curva Precision-Recall en el conjunto de test.

capacidad de discriminación, con un AUC de 0.9571, mientras que la curva Precision-Recall (Figura 1c) refleja un buen balance entre precisión y recall, con un AUC-PR de 0.8688, crucial para evitar no solo diagnósticos erróneos, sino también la omisión de casos positivos.

La Tabla 1 resume las principales métricas obtenidas en el conjunto de test:

Cuadro 1: Métricas de desempeño en el conjunto de test balanceado.

Métrica	**Accuracy**	**Precision**	**Recall**	**F1 Score**	**AUC-ROC**	**AUC-PR**
Valor	0.9459	0.9398	0.9398	0.9398	0.9571	0.8688

Estas métricas muestran un buen desempeño del modelo en la detección de tumores malignos y benignos.

1.3.2. Entrenamiento y Evaluación en el conjunto desbalanceado

Para evaluar la robustez del modelo en escenarios con desbalance de clases, se aplicaron sobre el conjunto de desarrollo cinco enfoques diferentes de rebalanceo:

1. **Sin rebalanceo**: Se entrenó el modelo directamente con los datos desbalanceados.
2. **Undersampling**: Se eliminaron muestras de la clase mayoritaria de forma aleatoria, obteniéndose una distribución equitativa entre ambas clases.
3. **Oversampling mediante duplicación**: Se replicaron aleatoriamente muestras de la clase minoritaria hasta igualar la cantidad de la clase mayoritaria.
4. **Oversampling mediante SMOTE:** Se generaron ejemplos sintéticos de la clase minoritaria interpolando entre instancias existentes.
5. **Cost re-weighting:** Se modifica la función de costo asignándole un peso mayor a los errores sobre la clase minoritaria. Esto se logra multiplicando los términos asociados a dicha clase por la razón $\frac{\pi_2}{\pi_1}$, donde π_1 y π_2 son las probabilidades a priori de la clase minoritaria y mayoritaria, respectivamente.

Para cada uno de estos enfoques se calcularon las métricas de desempeño explicadas en la sección 1.2.3: Accuracy, Precision, Recall, F1 Score, AUC-ROC y AUC-PR. En la Tabla 2 se resumen los resultados obtenidos en el conjunto de test a partir del entrenamiento con todo el conjunto de desarrollo:

Cuadro 2: Métricas de desempeño en test para distintos métodos de rebalanceo

Modelo	**Accuracy**	**Precision**	**Recall**	**F1**	**AUC-ROC**	**AUC-PR**
Sin rebalanceo	0.9338	0.8571	0.8824	0.8696	0.967	0.7827
Undersampling	0.9559	0.85	1.0	0.9189	0.9663	0.7738
Oversampling duplicate	0.9485	0.8461	0.9706	0.9041	0.9674	0.7839
Oversampling SMOTE	0.9412	0.825	0.9706	0.8919	0.9647	0.7486
Cost re-weighting	0.9485	0.8461	0.9706	0.9041	0.965	0.7491

Las curvas ROC y Precision-Recall fueron trazadas para cada técnica de rebalanceo (ver la Figura 2).

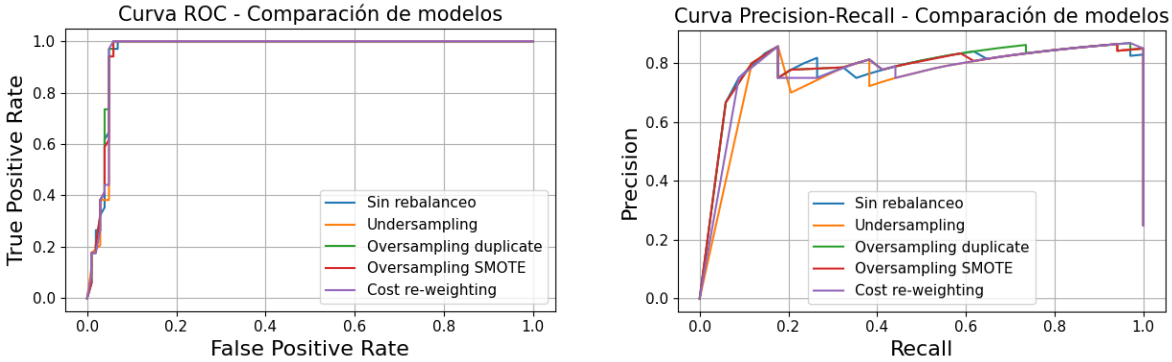

(a) Curva ROC para cada método

(b) Curva PR para cada método

Figura 2: Curvas ROC y Precision-Recall para la evaluación en el conjunto de test para distintos métodos de rebalanceo.

Se observa que el modelo sin rebalanceo presenta un desempeño moderado (Accuracy de 0.9338 y F1 de 0.8696), mientras que las estrategias de rebalanceo elevan significativamente el Recall, alcanzando en algunos casos el valor de 1.0 (como con undersampling). No obstante, el incremento en el Recall viene acompañado de variaciones en el AUC-PR, indicador especialmente relevante en contextos de clases desbalanceadas.

En particular, el método de oversampling mediante duplicación ofrece un Recall cercano a 0.97 y un F1 de 0.9041, logrando además el mayor AUC-PR (0.7839) entre los métodos, lo que sugiere un buen equilibrio entre la identificación de positivos y la contención de falsos positivos. Por su parte, el método basado en SMOTE y el enfoque de cost re-weighting también alcanzan un Recall alto (0.9706) y F1 de 0.9041, aunque con AUC-PR más bajos (0.7486 y 0.7491, respectivamente). El método de undersampling, pese a lograr un Recall perfecto (1.0), presenta un AUC-PR de 0.7738, ligeramente inferior al obtenido sin rebalanceo (0.7827).

En resumen, los métodos de oversampling demuestran ser muy efectivos para este proble-

ma. En particular, la variante de duplicación se posiciona como la más robusta, al combinar un alto Recall con el mayor AUC-PR, lo cual indica que es la opción que mejor equilibra la identificación de casos positivos y la reducción de falsos positivos.

2. Predicción de Rendimiento de Jugadores de Basketball

Resumen

En esta sección se abordó la predicción del rendimiento de jugadores de basketball a partir de variables estadísticas y físicas individuales, mediante modelos de clasificación multiclase. Para ello, se desarrollaron e implementaron tres enfoques: regresión logística multiclase con regularización L2, Análisis Discriminante Lineal (LDA) y Random Forest con calibración probabilística. El conjunto de datos fue dividido en entrenamiento, validación y test, y se aplicó un preprocesamiento que incluyó análisis de outliers e imputación con KNN y estandarización de características. Los hiperparámetros de cada modelo fueron seleccionados mediante Grid-Search maximizando el F1 Score. En el conjunto de test, el modelo de Random Forest calibrado mostró el mejor desempeño global, aunque con una menor capacidad de calibración en comparación con la regresión logística (AUC-PR de 0.5650 vs. 0.8704). Estos resultados evidencian un buen rendimiento general de los modelos, destacándose el Random Forest calibrado como el más robusto para entornos de producción, mientras que la regresión logística se perfila como una alternativa más interpretable y competitiva.

2.1. Introducción

El problema de Predicción de Rendimiento de Jugadores de Basketball se enfoca en estimar el impacto de un jugador en el desempeño de su equipo, medido en términos de Wins Above Replacement (WAR). Las entradas del algoritmo consisten en un conjunto de variables que describen diferentes aspectos del rendimiento individual de los jugadores, recopiladas a lo largo de múltiples temporadas. Estos datos incluyen estadísticas de juego, indicadores físicos y otras métricas relevantes. Utilizando técnicas de clasificación se obtiene una predicción del rendimiento del jugador, clasificándolo en categorías como "Negative WAR", "Null WAR" o "Positive WAR".

2.2. Métodos

En esta sección describimos los tres algoritmos implementados para la predicción de rendimiento de jugadores de basketball: regresión logística multiclase, Análisis Discriminante Lineal (LDA) y Bosques Aleatorios (Random Forest).

2.2.1. Regresión Logística Multiclase

La extensión de la regresión logística al caso multiclase se realiza mediante la estrategia "multinomial". En lugar de un único vector de pesos y sesgo, disponemos de C vectores de pesos $\{\mathbf{w}_c\}_{c=1}^{C}$, $\mathbf{w}_c \in R^D$, y sesgos $\{b_c\}_{c=1}^{C}$, $b_c \in R$. Para cada muestra $\mathbf{x}$ se calculan los *scores*

$$s_c(\mathbf{x}) = \mathbf{w}_c^\top \mathbf{x} + b_c, \quad \mathbf{s}(\mathbf{x}) = [s_1(\mathbf{x}), \ldots, s_C(\mathbf{x})]^\top,$$

y las probabilidades de clase se obtienen aplicando la función *softmax*:

$$p(y = c \mid \mathbf{x}; \Theta) = \frac{\exp\big(s_c(\mathbf{x})\big)}{\sum_{c'=1}^{C} \exp\big(s_{c'}(\mathbf{x})\big)}.$$

La función de pérdida es la entropía cruzada multiclase regularizada

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{n=1}^{N} \sum_{c=1}^{C} y_{n,c} \log\, p(y = c \mid x_n; \theta) + \frac{\lambda}{2} \sum_{c=1}^{C} \|w_c\|^2,$$

y la optimización se lleva a cabo por descenso por gradiente de forma análoga al caso binario explicado en la Sección 1.2.1.

2.2.2. Análisis Discriminante Lineal (LDA)

LDA es un modelo generativo que asume

$$\mathbf{x} \mid y = c \sim \mathcal{N}(\boldsymbol{\mu}_c, \Sigma), \quad \pi_c = P(y = c).$$

Los parámetros se estiman por máxima verosimilitud:

$$\hat{\boldsymbol{\mu}}_c = \frac{1}{N_c} \sum_{n:y_n=c} \mathbf{x}_n, \quad \hat{\pi}_c = \frac{N_c}{N}, \quad \hat{\Sigma} = \frac{1}{N - C} \sum_{c=1}^{C} \sum_{n:y_n=c} (\mathbf{x}_n - \hat{\boldsymbol{\mu}}_c)(\mathbf{x}_n - \hat{\boldsymbol{\mu}}_c)^\top.$$

La función discriminante para cada clase es

$$\delta_c(\mathbf{x}) = \mathbf{x}^\top \Sigma^{-1} \boldsymbol{\mu}_c - \tfrac{1}{2}\, \boldsymbol{\mu}_c^\top \Sigma^{-1} \boldsymbol{\mu}_c + \log \pi_c,$$

y la predicción se obtiene como

$$\hat{y} = \arg\max_c\, \delta_c(\mathbf{x}).$$

2.2.3. Bosques Aleatorios (Random Forest)

El Random Forest combina M árboles de decisión $\{f_m\}_{m=1}^{M}$ entrenados en muestras bootstrap. Para cada árbol se extrae con reemplazo un subconjunto $(X^{(m)}, y^{(m)})$ de tamaño N, se entrena un `DecisionTree` con criterio de entropía y profundidad máxima, y luego se agregan las predicciones por votación mayoritaria:

$$\hat{y} = \operatorname{mode}\big\{f_1(\mathbf{x}),\, f_2(\mathbf{x}), \ldots, f_M(\mathbf{x})\big\}, \quad \hat{p}(y = c \mid \mathbf{x}) = \frac{1}{M} \sum_{m=1}^{M} I\{f_m(\mathbf{x}) = c\}.$$

Opcionalmente, si se requiere calibración de probabilidades, se aplica *Platt scaling* a cada clase:

$$p_c^{\text{cal}} = \sigma\big(w_c\, \hat{p}(y = c \mid \mathbf{x}) + b_c\big), \quad \sigma(z) = \frac{1}{1 + e^{-z}},$$

ajustando los parámetros (w_c, b_c) por regresión logística en un conjunto de validación.

2.2.4. Conjunto de Datos y Preprocesamiento

Para el problema de predicción de rendimiento de jugadores se dispuso de una partición de desarrollo y una de test. La partición de desarrollo se subdividió aleatoriamente en 80 % para entrenamiento y 20 % para validación, reservando la partición de test para la evaluación final.

En la etapa de preprocesamiento se llevó a cabo un análisis de calidad de datos que incluyó la identificación de posibles valores faltantes, filas duplicadas y verificación del balance de clases, confirmando una distribución equilibrada entre las tres categorías de rendimiento. A continuación, se examinaron los rangos de las variables numéricas para detectar outliers, los cuales se trataron como valores faltantes y se imputaron tal como se describe en la Sección 2.4 de manera análoga al inciso anterior. Tras un análisis de correlación se detectó una variable que filtraba información de la variable objetivo (`war_total`) que fue eliminada del conjunto.

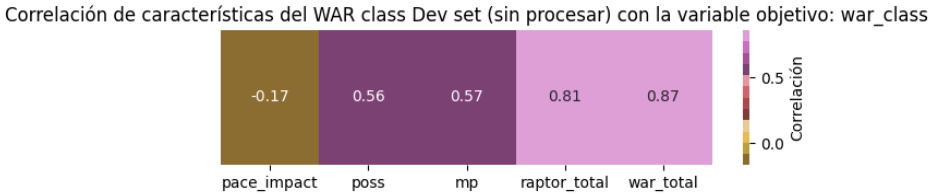

Figura 3: Visualización de la correlación de cada variable con la variable objetivo.

Finalmente, las características numéricas fueron normalizadas mediante estandarización donde μ y σ se calcularon sobre el conjunto de entrenamiento y luego se aplicaron tanto a validación como a test, de manera análoga al inciso anterior.

2.2.5. Selección de Hiperparámetros y Métricas

Para cada modelo definimos un espacio de búsqueda de hiperparámetros mediante GridSearch. En la regresión logística multiclase exploramos el coeficiente de regularización L2 $\lambda \in \{0{,}01, 0{,}1, 1, 10\}$, la tasa de aprendizaje $\alpha \in \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}\}$ y el número de iteraciones $\{300, 500, 1000,\ 1500\}$. En el bosque aleatorio probamos el número de árboles $M \in \{5, 10, 20, 50\}$, la profundidad máxima $D \in \{3, 5, 10, 15, \infty\}$ y el tamaño mínimo de muestras por nodo $n_{\text{mín}} \in \{1, 2, 5, 10\}$. Cada combinación se entrenó sobre el conjunto de entrenamiento y se evaluó en validación, seleccionando la configuración que maximizó el F1 Score. Con los hiperparámetros óptimos, los modelos se reentrenaron sobre la partición de desarrollo completa y se evaluaron en test.

Para la comparación de desempeño se emplearon las mismas métricas que las explicadas en la sección 1.2.3: matriz de confusión, accuracy, precision, recall, F1 Score, curvas ROC y Precision–Recall, así como los valores de AUC–ROC y AUC–PR.

2.3. Resultados

El desempeño de los modelos para la predicción de rendimiento se evaluó en el conjunto de test, considerando los modelos explicados en la sección 2.2, es decir, la Regresión Logística Multiclase, el Análisis Discriminante Lineal (LDA) y un modelo basado en Random Forest con y sin calibración mediante Platt.

En primer lugar, el modelo de Regresión Logística Multiclase demostró un desempeño sólido. Como se observa en la Figura 4, el modelo logra diferenciar de forma adecuada entre las categorías de rendimiento. Esto se refleja en un AUC-ROC de 0.9766 y un AUC-PR de 0.8704 (ver Tabla 4), lo cual indica que, si bien las métricas de exactitud y de F1 se sitúan en torno a 0.92, el modelo posee una buena capacidad para asignar probabilidades que ordenen correctamente las instancias según su relevancia para la clase positiva.

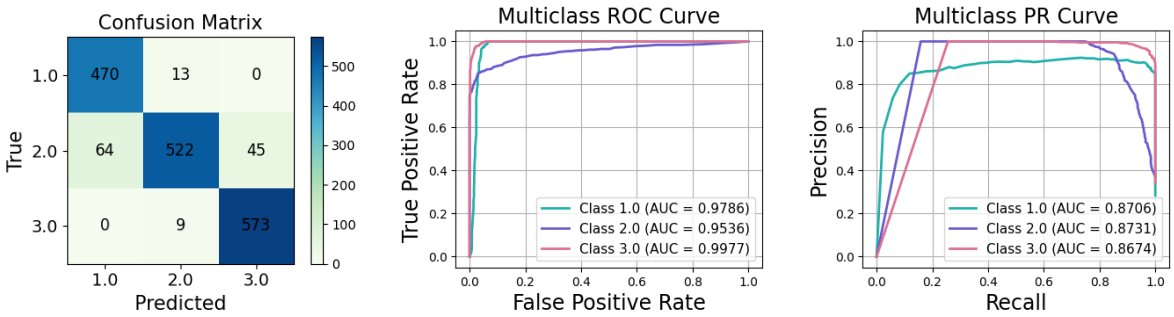

(a) Matriz de confusión (b) Curva ROC (c) Curva Precision-Recall

Figura 4: Resultados de Regresión Logística Multiclase en el conjunto de test.

Por otro lado, el modelo LDA, ilustrado en la Figura 5, presentó un rendimiento similar aunque ligeramente inferior al de la Regresión Logística. Los valores de Accuracy y de las métricas de clasificación se sitúan en torno a 0.90, con un AUC-ROC de 0.9732 y AUC-PR de 0.8656 (según Tabla 4). Esto sugiere que, si bien LDA es competitivo, la capacidad de discriminación global y la calibración de las probabilidades son marginalmente mejores en el modelo de Regresión Logística.

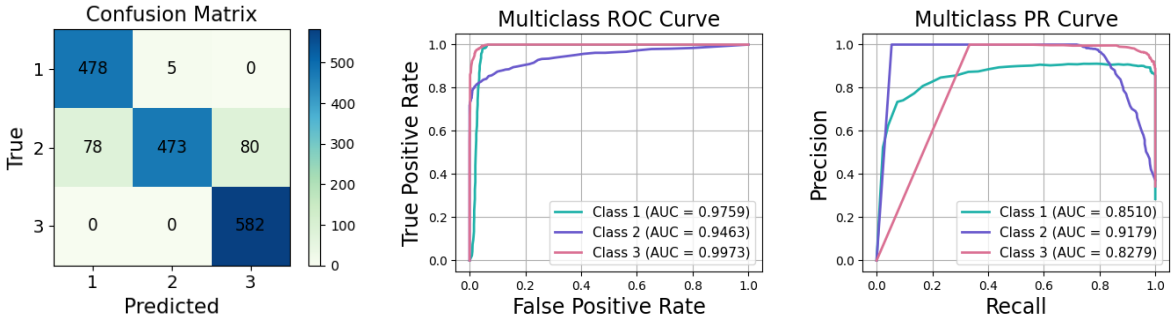

(a) Matriz de confusión (b) Curva ROC (c) Curva Precision-Recall

Figura 5: Resultados de Análisis Discriminante Lineal en el conjunto de test.

El modelo de Random Forest se evaluó considerando dos configuraciones: sin calibración y con calibración mediante Platt para mejorar la relación Precision-Recall. La Figura 6 presenta dos versiones de la curva, una convencional y otra tras la aplicación de Platt Scaling.

La comparación de desempeño entre ambas configuraciones se resume en la Tabla 3.

La comparación global de las métricas (ver Tabla 4) muestra que la Regresión Logística Multiclase obtiene un AUC-PR de 0.8704, mientras que LDA se ubica ligeramente por debajo

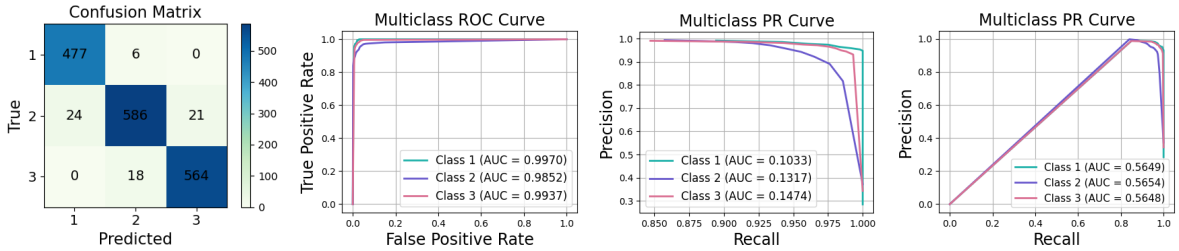

(a) Matriz de confusión (b) Curva ROC (c) Curva PR (s/ c) (d) Curva PR (con Platt)

Figura 6: Resultados del modelo de Random Forest en el conjunto de test.

Cuadro 3: Comparación de desempeño entre Random Forest con y sin calibración Platt.

Modelo	Accuracy	Precision	Recall	F1 Score	AUC-ROC	AUC-PR
RF (sin Platt)	0.964	0.9638	0.9663	0.9649	0.9909	0.1274
RF con Platt	0.9593	0.9590	0.9618	0.9602	0.9919	0.5650

con 0.8656. En cambio, a pesar de que la versión de Random Forest con calibración presenta el mayor valor de AUC-ROC (0.9919) y una Accuracy superior (0.9593), su AUC-PR (0.5650) es considerablemente menor, lo cual evidencia una limitación en su capacidad para ordenar correctamente las instancias en relación a la clase positiva.

Cuadro 4: Comparación de métricas en el conjunto de test para distintos modelos.

Modelo	Accuracy	Precision	Recall	F1 Score	AUC-ROC	AUC-PR
MLR	0.9228	0.9223	0.9283	0.9226	0.9766	0.8704
LDA	0.9039	0.9095	0.9131	0.9029	0.9732	0.8656
RF con Platt	0.9593	0.9590	0.9618	0.9602	0.9919	0.5650

En base a las métricas evaluadas, se observa que el modelo de Random Forest con selección de hiperparámetros `('n_trees': 10, 'max_depth': 10, 'min_samples': 1)` y calibración mediante Platt Scaling resulta el mejor candidato para producción. Si bien este modelo, al requerir validación, no queda entrenado con la totalidad del conjunto de desarrollo, su desempeño en el set de test es prácticamente equivalente al obtenido cuando se utiliza todo el set . Además, la aplicación de Platt Scaling mejora notablemente la calidad de las probabilidades, elevando el AUC-PR de 0.1274 a 0.5650, lo que indica una mayor capacidad para ordenar correctamente las instancias positivas. En contraste, si se prioriza la interpretabilidad y se prefiere una calibración intrínseca sin ajustes adicionales, la Regresión Logística Multiclase se presenta como una opción muy competitiva, con un AUC-PR de 0.8704 y métricas generales sólidas, aunque ligeramente inferiores en términos globales.

En conjunto, esto sugiere que, para entornos de producción donde se valore la robustez y la precisión en la estimación de probabilidades, el Random Forest con Platt Scaling es el candidato ideal, mientras que la Regresión Logística Multiclase podría ser preferida en escenarios en que la interpretabilidad y la simplicidad sean priorizados.

Apéndice

2.4. Uso del algoritmo KNN para imputación de valores faltantes

El algoritmo KNN (k-nearest neighbors) para imputación se basa en la idea de que las instancias con valores similares en las variables conocidas probablemente también sean similares en aquellas con valores faltantes. Para cada observación incompleta, se identifican sus k vecinos más cercanos utilizando como métrica la distancia euclídea, calculada únicamente sobre las variables numéricas previamente normalizadas. Luego, los valores faltantes se imputan a partir de la media (para variables numéricas) o la moda (para variables categóricas) de los vecinos válidos. Esta técnica preserva relaciones locales entre los datos y resulta particularmente útil cuando los valores ausentes no siguen un patrón completamente aleatorio.

A modo de ejemplo, en la Figura 7 se muestra la distribución de la variable `CytoplasmSize` antes y después del preprocesamiento.

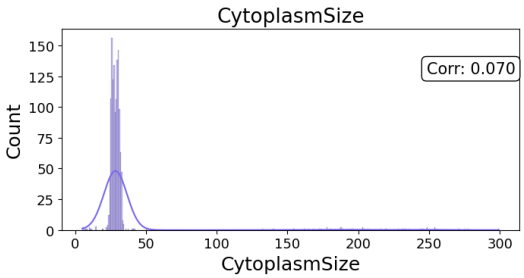

(a) Distribución original (`CytoplasmSize`) antes del preprocesamiento.

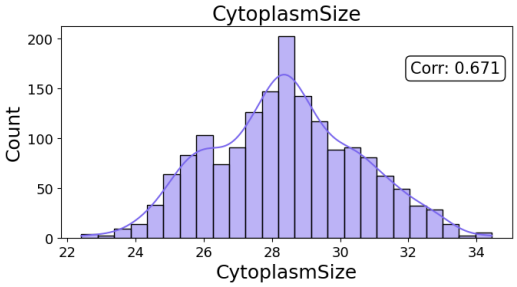

(b) Distribución tras limpieza e imputación con KNN.

Figura 7: Ejemplo del efecto del preprocesamiento sobre la variable `CytoplasmSize` con su respectiva correlación con la variable objetivo `Diagnosis`

Referencias

[1] Kevin P. Murphy. *Probabilistic Machine Learning: An Introduction*. MIT Press, Cambridge, Massachusetts, London, England, 2022.